网络重建中的 L1+ 交叉验证与 MDL 正则：背景、公式与推导（笔记）

目录

1 整体背景：为何“模型复杂度选择”是网络重建的核心难点 2

1.1 网络重建的推断式表述（generative + inference） 2

1.2 为什么必须正则化：$O(N^2)$ 参数 + 0 边与小权重边不可辨识 2

1.3 贝叶斯视角：MAP = 似然项 + 先验（正则）项 2

2 L1 正则：从 Laplace 先验到 LASSO；为何会产生精确零与收缩偏置 3

2.1 Laplace 先验 $\Longleftrightarrow$ L1 惩罚 3

2.2 凸性：为何 L1 在工程上“好用” 3

2.3 KKT / 次梯度推导：为何 L1 会产生精确的 0 3

2.4 soft-threshold（近端算子）推导：一维闭式解 4

2.5 收缩偏置（shrinkage bias）：稀疏与幅度被同一个 λ 绑在一起 4

2.6 （可选）坐标下降在“二次近似”下的更新形式 4

3 交叉验证（CV）：目标、公式、以及在网络重建中的典型陷阱 4

3.1 为何需要 CV：λ 无法从 MAP 自然确定 4

3.2 K 折 CV 的标准定义（以最大化 held-out 对数似然为例） 5

3.3 时间序列/依赖数据的 CV 提醒 5

3.4 为何 CV 在 L1 网络重建里仍可能过拟合：目标不一致 + 收缩伤害似然 5

4 MDL（最小描述长度）原则：从编码到贝叶斯，再到“可计算的模型复杂度” 5

4.1 Shannon 码长：$-\log P$ 为什么是“信息量” 5

4.2 两部编码（two-part code）与 MDL 的核心思想 5

4.3 贝叶斯与 MDL 的等价桥梁：联合概率的描述长度 6

4.4 关键坑：连续参数的先验是密度，$-\log p(W)$ 不是信息量 6

5 论文的 MDL 正则化：权重量化 + 辅助变量 A + 分层（hierarchical）非参数先验 6

5.1 第一步：显式引入稀疏结构 A（邻接矩阵） 6

5.2 第二步：显式引入精度——把权重离散化（量化） 6

5.3 第三步：给定 A，把“零权重”与“非零权重”分开建模 7

5.4 第四步：权重类别（categories）z 与非参数性（K 会自适应） 7

5.5 MDL 正则的三大性质（对应论文的动机清单） 7

5.6 与 L1 的关键对比（概念层） 7

6 与 Ising / kinetic Ising 的连接：为何会出现 cosh 与 logistic 形式 **8**
6.1 equilibrium Ising 的 pseudolikelihood（避免配分函数） 8
6.2 kinetic Ising：马尔可夫链的转移概率 8

7 把两套思想落到“可操作”的要点清单（学习/复现用） **8**
7.1 L1 + CV：你需要掌握的最小闭环 8
7.2 MDL：你需要掌握的最小闭环 8

8 总结：为什么论文认为 MDL 方案在该问题上更“对口” **9**

1 整体背景：为何“模型复杂度选择”是网络重建的核心难点

1.1 网络重建的推断式表述（generative + inference）

在推断式网络重建中，我们不把“网络”当成由相关系数直接算出来的产物，而是把它作为生成模型的参数：

$$P(X \mid W), \tag{1}$$

其中 X 为观测数据，$W \in \mathbb{R}^{N\times N}$ 为对称无向网络的权重矩阵（常令 $W_{ii}=0$）。论文强调两种常见数据组织方式：

(i) 独立样本： X 是 $N \times M$ 的样本矩阵 X_{im}，则

$$P(X \mid W) = \prod_{m=1}^{M} P(x^{(m)} \mid W). \tag{2}$$

(ii) 马尔可夫时间序列： $x(t)$ 为时刻 t 的全体节点状态，

$$P(X \mid W) = \prod_{t=0}^{M-1} P(x(t+1) \mid x(t); W). \tag{3}$$

目标是从 X 反推最可能的 W，并且给出“数据能支持的”复杂度。

1.2 为什么必须正则化：$O(N^2)$ 参数 + 0 边与小权重边不可辨识

无向图潜在边数为 $\binom{N}{2} = O(N^2)$，而很多真实系统期望稀疏（边数 $O(N)$）。如果只做最大似然，往往无法在有限样本下区分

$$W_{ij} = 0 \quad \text{vs} \quad W_{ij} \approx 0(\text{但非零}),$$

从而倾向推断出“几乎所有边都带一点点权重”的**最大密度网络**——这就是过拟合的典型形式。

1.3 贝叶斯视角：MAP = 似然项 + 先验（正则）项

贝叶斯后验：

$$P(W \mid X) = \frac{P(X \mid W)P(W)}{P(X)}. \tag{4}$$

论文以 MAP 为主（点估计）：

$$\hat{W} = \arg\max_{W} P(W \mid X) = \arg\max_{W} \Big[\log P(X \mid W) + \log P(W)\Big]. \tag{5}$$

因此“正则化”本质就是选择先验 $P(W)$，让推断偏向更简单（更可泛化）的网络。

2 L1 正则：从 Laplace 先验到 LASSO；为何会产生精确零与收缩偏置

2.1 Laplace 先验 $\Longleftrightarrow$ L1 惩罚

对每条无向边独立使用 Laplace（双指数）先验：

$$P(W \mid \lambda) = \prod_{i<j} \frac{\lambda}{2} \exp\bigl(-\lambda |W_{ij}|\bigr). \tag{6}$$

将其带入 (5)，得到优化目标（忽略与 W 无关的常数）：

$$\hat{W}(\lambda) = \arg\max_{W} \Bigl[\log P(X \mid W) - \lambda \sum_{i<j} |W_{ij}|\Bigr]. \tag{7}$$

这就是网络重建中的 L1（LASSO 型）正则：**在对数似然上减去 L1 范数罚项**。

2.2 凸性：为何 L1 在工程上“好用”

L1 惩罚 $\sum |W_{ij}|$ 是凸函数。若 $\log P(X \mid W)$ 是凹函数（等价于 $-\log P$ 是凸），则 (7) 是凸优化问题，可以用非常高效的算法（坐标下降、近端梯度、L-BFGS 的变体等）。

2.3 KKT / 次梯度推导：为何 L1 会产生精确的 0

将问题写成最小化形式更常见。设负对数似然

$$\mathcal{L}(W) := -\log P(X \mid W),$$

则 (7) 等价于

$$\hat{W}(\lambda) = \arg\min_{W} \Bigl[\mathcal{L}(W) + \lambda \sum_{i<j} |W_{ij}|\Bigr]. \tag{8}$$

对某个坐标 $w \equiv W_{ij}$，KKT（次梯度）条件为

$$0 \in \frac{\partial \mathcal{L}}{\partial w} + \lambda\, \partial |w|. \tag{9}$$

其中

$$\partial |w| = \begin{cases} \{+1\}, & w > 0, \\ [-1, +1], & w = 0, \\ \{-1\}, & w < 0. \end{cases}$$

因此若最优解满足 $w^\star = 0$，则必须存在 $s \in [-1, 1]$ 使

$$\frac{\partial \mathcal{L}}{\partial w}\Big|_{w=0} + \lambda s = 0 \quad \Longleftrightarrow \quad \left| \frac{\partial \mathcal{L}}{\partial w}\Big|_{w=0} \right| \le \lambda.$$

结论：当“把该边从 0 往非零推”的一阶驱动力不超过阈值 λ 时，最优解会把它钉在 0。这就是 L1 的“阈值化”机制，也是它自然产出稀疏解的原因。

2.4 soft-threshold（近端算子）推导：一维闭式解

考虑最经典的 1D 子问题（常出现在近端梯度/坐标下降推导中）：

$$w^\star = \arg\min_w \frac{1}{2}(w-u)^2 + \lambda|w|. \tag{10}$$

对 $w>0$ 与 $w<0$ 分别求导：

$$w-u+\lambda=0 \Rightarrow w=u-\lambda \quad (w>0), \qquad w-u-\lambda=0 \Rightarrow w=u+\lambda \quad (w<0).$$

再检查可行性得到闭式解：

$$w^\star = \mathrm{soft}(u,\lambda) \coloneqq \mathrm{sign}(u)\max\{|u|-\lambda,\,0\}. \tag{11}$$

两层含义：

- **精确零：** $|u| \le \lambda \Rightarrow w^\star = 0$；
- **收缩：** $|u| > \lambda \Rightarrow w^\star$ 比 u 少了 λ 的幅度。

2.5 收缩偏置（shrinkage bias）：稀疏与幅度被同一个 λ 绑在一起

由 (11) 立刻看出：L1 不仅让很多边变为 0，也会把保留下来的非零边系统性压小。这会带来两种后果（对网络重建尤关键）：

1. **结构选择（是否有边）**与 **幅度估计（边权多大）**无法解耦；
2. 当你把 λ 调大以得到正确稀疏结构时，你必然牺牲非零权重的无偏性，从而影响预测似然与泛化。

2.6 （可选）坐标下降在“二次近似”下的更新形式

很多场景里可对 $\mathcal{L}$ 在坐标 w 上做局部二次近似：

$$\mathcal{L}(w) \approx \mathcal{L}(w_0) + g(w-w_0) + \frac{1}{2}h(w-w_0)^2,$$

其中 $g = \partial\mathcal{L}/\partial w|_{w_0}$，$h$ 是二阶曲率（或近似 Hessian 对角元）。代回 (8) 并丢掉常数项，得到

$$\min_w \ \frac{1}{2}h\Big(w-(w_0-\frac{g}{h})\Big)^2 + \lambda|w|.$$

因此更新就是一个 soft-threshold：

$$w \leftarrow \mathrm{soft}\Big(w_0-\frac{g}{h},\,\frac{\lambda}{h}\Big). \tag{12}$$

这解释了为什么 L1 的高效算法常常能写成“梯度一步 + 阈值化一步”。

3 交叉验证（CV）：目标、公式、以及在网络重建中的典型陷阱

3.1 为何需要 CV：λ 无法从 MAP 自然确定

L1 的关键超参是 λ。它决定稀疏度：λ 越大边越少。但真实问题中我们通常不知道应有多少边，因此常用交叉验证从数据中选 λ。

3.2 K 折 CV 的标准定义（以最大化 held-out 对数似然为例）

把数据划分为 K 份 $X = \{X_1, \ldots, X_K\}$，对每个 k：

$$\hat{W}_{-k}(\lambda) = \arg\max_{W} \Big[\log P(X \setminus X_k \mid W) + \log P(W \mid \lambda)\Big], \tag{13}$$

$$L_k(\lambda) = \log P(X_k \mid \hat{W}_{-k}(\lambda)). \tag{14}$$

最后选

$$\hat{\lambda} = \arg\max_{\lambda} \frac{1}{K} \sum_{k=1}^{K} L_k(\lambda). \tag{15}$$

注意：这等价于“选能最好预测未见数据的模型”（预测视角）。

3.3 时间序列/依赖数据的 CV 提醒

若数据是马尔可夫序列（kinetic Ising 一类），随机打乱会破坏时间依赖。更稳妥的做法是用 block CV（按连续时间段划分），或用前段训练后段测试等方案。（论文 Fig.1 的 synthetic 例子采用 kinetic Ising 转移数据并进行 CV，作为说明性例子。）

3.4 为何 CV 在 L1 网络重建里仍可能过拟合：目标不一致 + 收缩伤害似然

CV 优化的是 held-out 似然 (15)，它对“把真边权压小”的惩罚很敏感：收缩越强，模型越“迟钝”，预测对数似然往往下降。因此 CV 可能倾向于选择较小的 λ 来避免收缩造成的似然损失，但较小 λ 又会容忍大量本应为 0 的“小伪边”，导致结构上过密的网络。

这正是论文 Fig.1 想强调的点： 五折 CV 选到的 λ 对应的推断网络仍然很稠密，含大量 spurious edges；而若把 λ 调到结构最像真网络，平均权重会被显著压小，预测性能变差。

（这些现象在 Fig.1 的图注与正文中被明确说明，并用两条竖虚线对照“CV 最优”与“结构最优”。）

4 MDL（最小描述长度）原则：从编码到贝叶斯，再到“可计算的模型复杂度”

4.1 Shannon 码长：$-\log P$ 为什么是“信息量”

设要编码的对象为随机变量 Y，若使用最优前缀码，平均码长下界是熵 $H(Y)$。对于具体结果 y，理想码长可写为

$$\ell(y) \approx -\log_2 P(y).$$

这就是 MDL 里“描述长度 = 负对数概率”的基本来源（底数决定单位：bit 或 nat）。

4.2 两部编码（two-part code）与 MDL 的核心思想

对“数据 + 模型”一起编码：

$$\ell(X, \text{model}) = \ell(\text{model}) + \ell(X \mid \text{model}).$$

MDL 的思想是：**选择使总描述长度最短的模型**，从而自动实现“拟合 vs 复杂度”的最优折中。

4.3 贝叶斯与 MDL 的等价桥梁：联合概率的描述长度

论文把这种联系写成（用自然对数时单位为 nat）：

$$\Sigma(X;W) := -\log P(X,W) \tag{16}$$

$$= -\log P(X \mid W) - \log P(W). \tag{17}$$

第一项是“已知参数时编码数据”的代价；第二项是“编码参数”的代价。最小化 Σ 就是在做最压缩、最简洁的模型选择。

4.4 关键坑：连续参数的先验是密度，$-\log p(W)$ 不是信息量

如果 W 被视为无限精度连续变量，则 $P(W)$ 是**概率密度** $p(W)$，这时 $-\log p(W)$ 不能稳定解释为“编码长度”，甚至会在变量变换下任意改变（雅可比因子）。

论文强调：这正是为什么 **Laplace(L1) 先验的 λ 不能通过“最压缩”原则（或 MAP）自然确定**——最可能不等于最可压缩。要正确量化复杂度，必须显式引入参数精度：把它们变成离散（概率质量函数）对象。

5 论文的 MDL 正则化：权重量化 + 辅助变量 A + 分层 (hierarchical) 非参数先验

本节是论文 Sec.IV 的核心：构造一个既能促稀疏、又不依赖收缩、还不需要 CV 的正则化先验。

5.1 第一步：显式引入稀疏结构 A（邻接矩阵）

用二值邻接矩阵 A 表示哪些边允许非零：

$$A_{ij} \in \{0,1\}, \quad A_{ij} = A_{ji}, \quad A_{ii} = 0.$$

给定总边数 $E = \sum_{i<j} A_{ij}$，可以令 A 在“具有 E 条边的图集合”上均匀：

$$P(A \mid E) = \binom{\binom{N}{2}}{E}^{-1}.$$

再给 E 一个简单先验（如均匀）即可。

直觉：这使得“边越少”通常对应更短的描述长度，因此天然偏好稀疏。

5.2 第二步：显式引入精度——把权重离散化（量化）

论文用一个量化步长 Δ 把连续值映射到离散格点（示例形式）：

$$W_{ij} = \Delta \left\lceil \frac{Y_{ij}}{\Delta} \right\rceil. \tag{18}$$

关键不是具体量化形式，而是：**一旦权重来自离散集合，$-\log P(W)$ 才能作为真实“码长”计算。**

5.3 第三步：给定 A，把“零权重”与“非零权重”分开建模

论文给出一种通用写法（思想是：若 $A_{ij}=0$ 则强制 $W_{ij}=0$）：

$$P(W \mid A) = \prod_{i<j} P(W_{ij})^{A_{ij}}\, \delta_{W_{ij},0}^{1-A_{ij}}. \tag{19}$$

其中 $P(W_{ij})$ 必须是离散质量函数（由量化保证）。

5.4 第四步：权重类别（categories）z 与非参数性（K 会自适应）

论文的关键升级是：不要预先指定一个固定形状的权重分布，而是让它**从数据中学习**。做法是引入

- K 个权重类别（类别中心）$z=(z_1,\ldots,z_K)$；
- 每条非零边被分配到某个类别（形成计数向量 m）；
- 类别本身也有先验（可带尺度参数 λ、精度参数 Δ 等）。

把这些潜变量边缘化（sum/integrate out）得到对 W 的分层先验：

$$P(W \mid \lambda,\Delta) = \sum_{z,K,A,E} P(W \mid z,A)\, P(z \mid \lambda,\Delta,K)\, P(K \mid A)\, P(A \mid E)\, P(E), \tag{20}$$

论文指出：Δ 控制的是类别 z 的精度，而权重 W 的“有效精度”主要由有限个类别本身承载；并且最小描述长度时通常会出现 $K \ll E$（少量类别解释大量边），从而能利用权重分布的规律性获得压缩。

非参数（nonparametric）在这里的含义： 不是“没有参数”，而是**参数个数（类别数 K）、类别位置、边数 E 都会随数据证据增长/收缩**，只要它们能进一步压缩数据（降低总描述长度），就保留；否则就被惩罚掉。

5.5 MDL 正则的三大性质（对应论文的动机清单）

该构造旨在同时实现：

1. **原则性：**复杂度惩罚来自真实可计算的描述长度；
2. **促稀疏：**通过 A,E 的编码长度自然偏好少边；
3. **不依赖 weight shrinkage：**稀疏主要通过“该不该为 0”的结构编码实现，而不是把非零整体压小。

5.6 与 L1 的关键对比（概念层）

L1：用一个连续超参 λ 同时控制“零的数量”和“非零幅度的收缩”，通常需要 CV 扫参。

MDL：通过（1）显式结构 A，（2）显式精度（离散/量化），（3）类别数自适应，让“稀疏度/权重分布/精度”成为推断输出，从而**不需要交叉验证，只需一次拟合**。

6 与 Ising / kinetic Ising 的连接：为何会出现 cosh 与 logistic 形式

论文在 Appendix A 给出 equilibrium Ising 的伪似然与 kinetic Ising 的转移概率。

6.1 equilibrium Ising 的 pseudolikelihood（避免配分函数）

对二值 $x \in \{-1,1\}^N$ 的 Ising，精确似然含配分函数 $Z(W,\theta)$ 难算，常用逐节点条件分布相乘的伪似然近似：

$$P(x \mid W,\theta) \approx \prod_i P(x_i \mid x_{\neg i}; W,\theta) = \prod_i \frac{\exp\bigl(x_i(\sum_j W_{ij}x_j + \theta_i)\bigr)}{2\cosh\bigl(\sum_j W_{ij}x_j + \theta_i\bigr)}. \tag{21}$$

这是标准 logistic/tanh 链接的形式：对每个 i，它像一个以 $x_{\neg i}$ 为特征的 logistic 回归。

6.2 kinetic Ising：马尔可夫链的转移概率

kinetic Ising 把模型写成马尔可夫链（每步对每个节点条件独立）：

$$P[x(t+1) \mid x(t); W,\theta] = \prod_i \frac{\exp\bigl(x_i(t+1)(\sum_j W_{ij}x_j(t) + \theta_i)\bigr)}{2\cosh\bigl(\sum_j W_{ij}x_j(t) + \theta_i\bigr)}. \tag{22}$$

因此对数似然就是对 t,i 求和的 logistic 回归损失，这也是为什么 L1/MDL 都能“外挂”到这种模型上。

7 把两套思想落到“可操作”的要点清单（学习/复现用）

7.1 L1 + CV：你需要掌握的最小闭环

1. 写出负对数似然 $\mathcal{L}(W) = -\log P(X \mid W)$（或伪似然）。
2. 形成目标：$\min_W \mathcal{L}(W) + \lambda\|W\|_1$。
3. 理解稀疏来自阈值化：$|\partial\mathcal{L}/\partial W_{ij}| \le \lambda \Rightarrow W_{ij} = 0$（KKT）。
4. 选择算法：近端梯度 / 坐标下降；核心更新等价于 soft-threshold。
5. 选 λ：K 折 CV 最大化 held-out log-likelihood（注意时间依赖时用 block）。
6. 评估时区分两类指标：预测指标（held-out likelihood）vs 结构指标（边集合相似度）。

7.2 MDL：你需要掌握的最小闭环

1. 从 $\Sigma(X;W) = -\log P(X,W)$ 出发，理解“拟合 + 模型码长”。
2. 牢记连续参数的坑：$-\log p(W)$ 不是信息量，必须引入精度（离散化/量化）。
3. 引入 A,E 把稀疏结构变成可编码对象：越稀疏通常码长越短。
4. 用类别 z 与类别数 K 让权重分布可学习：只要能压缩数据就增长，否则收缩。
5. 整体目标：直接最小化描述长度（等价最大化联合概率），无需 CV。

8 总结：为什么论文认为 MDL 方案在该问题上更“对口”

网络重建的“难”不在于优化本身，而在于**模型复杂度选择必须从数据中自动产生**。

L1 的优势是凸、好算、会出精确零；但它把稀疏与收缩绑死，并且需要 CV 扫 λ，在很多重建任务中即便 CV 也会留下大量伪边。

MDL 的方案把“稀疏结构 + 权重精度/分布”都纳入可计算的描述长度框架，用“能否压缩数据”作为统一准则，从而在原则性、抗过拟合与可扩展性上更契合论文的目标。